


## OVERFITTING

El sobreentrenamiento (overfitting) es la tendencia que tiene un algoritmo de machine learning de memorizar características de los datos utilizados en el entrenamiento.

El modelo puede identificar patrones que no estamos buscando en los datos de entrenamiento y memorizarlos, esto provocará que al evaluar nueva información con el algoritmo después del entrenamiento, este no sea capaz de completar la tarea para la que fue diseñado.




BAJO ENTRENAMIENTO

CAPACIDAD  
NORMAL

SOBRE ENTRENAMIENTO

Los modelos menos capaces tendrán mayor dificultad para encontrar los patrones indicados en los datos y a la inversa, modelos altamente capaces tenderán a memorizar las propiedades de los datos de entrenamiento. El truco está en identificar el comportamiento del modelo antes de que se sobreentrene.

La relación entre la capacidad y el error del modelo se muestra en la siguiente imagen:



El error durante el entrenamiento y la validación se comporta de forma diferente, comunmente en el entrenamiento decrese y tiene un comportamiento asíntótico que tiende al valor mínimo posible, mientras que la capacidad aumenta.

Todos los algoritmos de machine learning tienden a sobreentrenarse en algún punto y en cierto grado.

Para detectarlo podemos evaluar el comportamiento del modelo con nuevos conjuntos de datos, es importante que esta información no haya sido vista por el modelo durante el entrenamiento.

Algunas de las estrategias para reparar o evitar el sobreentrenamiento son:



Regularización de los datos (L1, L2, Dropout, Dropconnect)

Early stopping

Un conjunto de datos más grande

Una red neuronal más pequeña

## EJEMPLO



Se entrenó un modelo de deep learning, una red neuronal convolucional con una base de datos aleatoria, en donde buscamos clasificar números.

Al término se grafican la información sobre la exactitud y el error en el entrenamiento y la validación. El comportamiento mostrado en las gráficas muestra que mientras en el entrenamiento la exactitud aumenta la validación no mejora, esto indica un posible sobreentrenamiento, el modelo encontró características no deseadas.

Lo mismo sucede en la gráfica del error, en el entrenamiento decrese y en la validación no llega a mejorar. Estas gráficas pueden ayudarte a interpretar el desempeño de tu algoritmo.